

Veri Seti İncelemesi ve Ön İşleme Planı

1. Giriş

Bu projede finansal işlem verileri kullanılarak işlemlerin analiz edilmesi ve olası dolandırıcılık faaliyetlerinin tespit edilmesi amaçlanmaktadır. Makine öğrenmesi modelleri uygulanmadan önce veri setinin iyi anlaşılması ve veri ön işleme adımlarının planlanması büyük önem taşımaktadır.

Bu raporda projede kullanılacak veri seti tanıtılacak, veri kalitesi değerlendirilecek ve veri temizleme, eksik veri işleme ve veri dönüştürme gibi ön işleme adımları planlanacaktır.

2. Veri Setinin Tanımı

Bu projede kullanılacak veri seti **Synthetic Financial Dataset for Fraud Detection** adlı veri setidir.

Bu veri seti gerçek finansal işlemleri simüle eden büyük bir veri setidir ve özellikle finansal dolandırıcılık tespiti çalışmalarında yaygın olarak kullanılmaktadır.

Veri seti dosya adı:

PS_20174392719_1491204439457_log.csv

Veri setindeki her satır bir finansal işlemi temsil etmektedir.

Veri setinde bulunan bazı önemli sütunlar şunlardır:

Sütun Adı	Açıklama
step	İşlemin gerçekleştiği zaman adımı
type	İşlem türü (TRANSFER, CASH_OUT, PAYMENT vb.)
amount	İşlem miktarı
nameOrig	Gönderici hesap
oldbalanceOrg	İşlem öncesi gönderici bakiyesi
newbalanceOrig	İşlem sonrası gönderici bakiyesi
nameDest	Alıcı hesap
oldbalanceDest	İşlem öncesi alıcı bakiyesi
newbalanceDest	İşlem sonrası alıcı bakiyesi
isFraud	İşlemin dolandırıcılık olup olmadığını gösterir

Bu veri seti finansal işlem davranışlarını analiz etmek ve şüpheli işlemleri tespit etmek amacıyla kullanılacaktır.

3. Veri Kalitesinin Değerlendirilmesi

Veri seti analiz edilmeden önce veri kalitesi değerlendirilecektir. Bu aşamada aşağıdaki kontroller yapılacaktır.

Eksik veri kontrolü

Veri setindeki tüm sütunlar eksik değer olup olmadığı açısından incelenecektir. Eksik veriler veri analizi ve makine öğrenmesi modellerinin performansını olumsuz etkileyebilir.

Bu nedenle eksik veriler tespit edilerek uygun yöntemlerle işlenecektir.

Veri türlerinin kontrol edilmesi

Her sütunun veri tipi kontrol edilecektir.

Örneğin:

- amount → sayısal veri
- step → tam sayı
- type → kategorik veri

Doğru veri tiplerinin kullanılması veri analizi için önemlidir.

Aykırı değer analizi

Bazı işlemler normalden çok daha yüksek işlem miktarlarına sahip olabilir. Bu tür değerler aykırı değer olarak kabul edilir.

Aykırı değerler istatistiksel yöntemler veya görselleştirme teknikleri kullanılarak analiz edilecektir.

4. Veri Temizleme Planı

Veri setinin analiz için uygun hale getirilmesi amacıyla bazı veri temizleme işlemleri uygulanacaktır.

Gereksiz sütunların kaldırılması

Analiz için gerekli olmayan sütunlar veri setinden çıkarılacaktır. Örneğin otomatik oluşturulan indeks sütunları analiz için gerekli olmayabilir.

Yinelenen verilerin kaldırılması

Veri setinde aynı işlemi temsil eden tekrar eden satırlar bulunabilir. Bu nedenle veri seti tekrar eden kayıtlar açısından kontrol edilecek ve gerekirse bu kayıtlar kaldırılacaktır.

Tutarsız verilerin düzeltilmesi

Veri setinde bazı değerler yanlış formatta veya tutarsız olabilir. Bu tür veriler analizden önce düzeltilerek veri setinin daha güvenilir hale gelmesi sağlanacaktır.

5. Eksik Verilerin İşlenmesi

Eksik veriler veri analizini olumsuz etkileyebilir. Bu nedenle eksik veriler uygun yöntemlerle ele alınacaktır.

Eksik satırların silinmesi

Eksik veri sayısı çok az ise bu satırlar veri setinden çıkarılabilir.

Eksik değerlerin doldurulması

Sayısal sütunlarda eksik değerler aşağıdaki yöntemlerle doldurulabilir:

- ortalama (mean)
- medyan (median)

Bu yöntemler veri dağılımını korumaya yardımcı olur.

6. Veri Dönüştürme

Makine öğrenmesi algoritmalarının veri ile daha iyi çalışabilmesi için bazı veri dönüştürme işlemleri yapılacaktır.

Kategorik verilerin sayısal verilere dönüştürülmesi

İşlem türü gibi kategorik veriler makine öğrenmesi algoritmaları tarafından doğrudan kullanılamaz. Bu nedenle bu tür veriler sayısal forma dönüştürülecektir.

Bu işlem **One-Hot Encoding** gibi yöntemlerle yapılabilir.

Veri ölçekleme

Bazı makine öğrenmesi algoritmaları veri ölçeklemesinden fayda sağlar. Bu nedenle sayısal veriler aşağıdaki yöntemlerle ölçeklendirilebilir:

- StandardScaler
- MinMaxScaler

Bu işlem model performansını artırabilir.

7. Sonuç

Bu raporda projede kullanılacak veri seti tanıtılmış ve veri ön işleme planı açıklanmıştır.

Projenin ilerleyen aşamalarında aşağıdaki adımlar uygulanacaktır:

- veri kalitesinin analiz edilmesi
- eksik verilerin tespit edilmesi
- veri temizleme işlemleri
- kategorik verilerin dönüştürülmesi
- sayısal verilerin ölçeklendirilmesi

Bu adımlar veri setinin daha güvenilir ve analiz için uygun hale gelmesini sağlayacaktır.

Ahmed Kannavi
24051603